

Apuntes de Heberht Castellon

Charla "Más allá del Prompt: Construyendo sistemas RAG para que tu IA deje de alucinar" · AWS Student Community Day Cochabamba 2026 · sábado 10 de octubre de 2026, 11:10–11:50, Auditorio BISA (Main Stage)

Código de la demo

El código completo de la charla de Heberht Castellon (la demo de RAG local) se puede descargar del repositorio en GitHub: <https://github.com/Hcc2023/mas-alla-del-prompt>

Contacto

Heberht Castellon, QA Engineer. LinkedIn: [linkedin.com/in/heberht-castellón-profesionalqa](https://www.linkedin.com/in/heberht-castellón-profesionalqa)

Tres ideas para llevarse

1. Un LLM sin RAG responde de memoria; con RAG responde a libro abierto y cita su fuente.
2. La calidad se mide: el dataset dorado es la suite de regresión de la IA, y el juez (LLM-as-a-Judge) también se prueba.
3. Lo que se vio en una laptop escala en AWS con Amazon Bedrock Knowledge Bases y Amazon S3 Vectors.

Stack de la demo

Ollama · qwen3:4b-instruct (generador) · embeddinggemma (embeddings) · ChromaDB · LangChain · búsqueda híbrida (embeddings + BM25) · Streamlit · gemma3:4b como juez. Corre 100% local, sin internet, en una GPU de 4 GB.